

深度學習與產業應用 HW4

Q1

NO	Window size	Step	MSE
1	30	10	30.3510
2	25	5	6.8379
3	20	2	2.6542

隨著 window size 和 step 的縮小，MSE 下降了很多。較小的 window size 與較密集的 step 可以讓模型獲得更多局部資訊，進而提升預測的細緻度與準確性，且有助於捕捉時間序列中的細微變化，降低預測誤差。然而同時也會增加資料量與計算負擔，使得程式在運算時所花的時間比較久。

Q2

- (i) 加入 'Volume' 後，MSE 變更大了。我認為可能是這項特徵本身對我們要預測的變數沒有太高的相關性，且波動大、雜訊多，所以讓整體模型的預測表現變差。並非加入越多特徵，表現就越好。無效特徵可能會導致預測效果下降。
- (ii) 我嘗試排列組合把四個特徵交替刪去，發現預測效果最好的是用兩個特徵：'High', 'Low'。我會這樣嘗試是因為我覺得開盤價跟收盤價可能沒有和預測的目標變數關聯性不高。最後我把前一題得到的最佳結果(window size, step)=(20, 2)和特徵一起調整，得到最佳的 MSE 為 1.7171

Q3

原本沒有正規化時跑出來的 MSE 是 328，但經過正規化後的 MSE 是 130。可以看出來正規化能讓特徵維持在特定範圍中，讓模型能更好的學習，也變得更穩定。因為不同特徵在同一數值的尺度上，模型在做梯度更新時才不會偏向某些特徵，這在特徵值差異很大的金融資料中尤為重要。

Q4

我認為 **window size** 比 **step** 小是錯的，因為這樣會沒辦法確保每次滑動時都能涵蓋足夠的資料，進而導致預測效果降低

Q5

在時間序列的資料增強中，常見的方法之一是加入噪聲。Liu 等人於研究中提出，透過在每筆樣本中加入標準常態分佈的少量噪聲（平均數為 0，變異數為 0.05），可以讓資料僅有微幅抖動，保持與原始資料相似的特性，同時擴增資料量並提升模型的泛化能力。此外，真實世界中的時間序列資料本身就常帶有微小雜訊，因此此方法既符合資料特性，也能有效緩解小樣本問題。

Reference:

Liu, B., Zhang, Z., & Cui, R. (2020, October). Efficient time series augmentation methods. In *2020 13th international congress on image and signal processing, BioMedical engineering and informatics (CISP-BMEI)* (pp. 1004-1009). IEEE.

Q6

- (i) CNN 是看固定長度的 **window**，模型會在這些 **window** 中提取區域性的特徵。**Window size** 決定了模型每次觀察的資料範圍。推論時，通常會用與訓練階段相同的 **window size**，並用滑動視窗的方式逐步進行掃描，從每個區段中進行預測。
- (ii) RNN 是一次讀入一個時間點，會保留過去輸入的記憶，並逐步處理整段序列。**Window size** 決定模型每次要輸入多長的一段資料。推論時，會用與訓練時相同的 **window size**，由前往後依序輸入，每個 **time step** 都會更新隱藏狀態，直到輸入整段序列為止。
- (iii) Transformer 模型會一次讀入整段輸入，不需要逐步讀取，因此對 **window size** 的處理方式也與其他模型不同。推論時，會根據訓練階段設定的固定長度分段輸入，如果輸入序列比 **window size** 長，則會切成多段處理。